

个人简历 应届生

张小明

所在地：广东深圳123

联系方式：zhangxiaoming@x.xxx

教育经历

大学名称 — 专业 — 学位 — 学年

技能

- 精通大语言模型预训练及 LoRA、QLoRA 高效微调方法，深入理解 Transformer 算法原理
- 熟练掌握机器学习、深度学习与强化学习理论，主导多模态大模型落地实践
- 深入应用 DPO、ORPO、PPO 等直接偏好优化算法，熟练驾驭 TRL 大模型对齐框架
- 精通 Adam、SGD 优化器及交叉熵、Dice 等损失函数，深谙模型训练核心逻辑
- 熟练运用 DeepSpeed、Accelerate 分布式训练技术，具备多机多卡并行训练实战经验
- 主导 Agent 智能体开发，精通任务规划、路由决策、Function Calling 与 MCP 工具集成
- 熟练使用 LangChain、LangGraph 开发框架，擅长上下文工程与 vLLM、Ollama 本地化部署
- 精通 Chroma、Milvus 向量数据库，熟练操作 MS-Swift、LLaMA-Factory、Unsloth 大模型微调工具
- 熟练集成 RapidOCR、MinerU、PaddleOCR 技术框架，精通 Pandas、NumPy、Scikit-learn 数据处理工具
- 主导 RAG 知识库与知识图谱搭建，深入应用 LightRAG、GraphRAG，熟练使用 RAGas、LangSmith 评测监控
- 精通 Linux 服务器部署与 Git、SVN 版本控制，熟练进行 Python、PyTorch 开发
- 独立完成 Dify、Coze 智能体全流程搭建，擅长私有知识库对接与意图设计，赋能业务提效

工作经历

公司名称 — 职位 — 省/市 — 工作时间

- 简要介绍工作职责和内容

项目经历

智慧校园学情多 Agent 智能平台 · 多 Agent + 大模型开发

项目时间：2025.09-2026.04技术栈：Python、MCP、A2AServer、LangChain、LoRA/PromptTuning/BERT+PET 微调、Milvus、MySQL、Redis、RAG、BGEM3、BM25、全局 MD 项目规范、模块化 Skill 技能库、GPTQ、vLLM、DeepSpeed、LLaMA-Factory

项目简介：面向学校、教培机构打造全角色智能服务。采用 A2A+MCP 多 Agent 调度平台，拆解六大业务智能体；轻量化微调 + RAG+Skill 三重约束；通过模型量化、推理加速、集群容器化，实现低配服务器部署，支持 ToB 机构 SaaS 年费商业模式。

核心职责：

- 设计六层企业架构，独立开发 A2AServer 网关；制定项目全局 MD 规范文档；按六大 Agent 业务拆分整套 Skill 技能库。
- 实现 MCP 多 Agent 调度平台，负责任务拆解、流程编排、多版本微调模型路由调度。
- 搭建教育 RAG 私有知识库，完成语料清洗、文本分块、Embedding 向量化，调优检索策略提升召回精度。
- 基于 LLaMA-Factory+DeepSpeed，落地 LoRA、Prompt-Tuning、BERT+PET 多模式小样本微调方案，适配教育场景轻量化模型需求。

技术难点与解决方案：

- 难点 1：多 Agent 任务调度链路复杂，跨智能体协作易冲突，多版本模型路由效率低 六大业务智能体覆盖学情分析、作业批改、答疑辅导等不同场景，复杂任务需多 Agent 协同拆解、串行 / 并行编排，易出现任务死锁、上下文丢失、重复调用问题；同时多版本微调模型对应不同场景，人工路由匹配精度差、资源浪费严重。解决方案：自研 A2AServer 网关 + MCP 多 Agent 调度平台，统一任务入口与上下文总线，实现任务自动拆解、依赖编排、状态同步与异常重试；搭建模型路由策略引擎，基于意图识别与场景标签自动匹配最优微调模型与 Skill 技能，任务执行效率提升 70%，调度准确率达 95% 以上。

- 难点 2：教育场景知识专业性强、场景细分度高，通用模型易出现幻觉，学情分析偏差大 不同学段、学科、教材版本知识体系差异大，通用大模型缺乏教育专属知识与答题规范，易出现知识点错误、解题步骤不标准、学情画像失真等问题，无法满足教培机构精准教学需求。解决方案：构建「轻量化微调 + RAG 私有知识库 + 模块化 Skill」三重约束体系；基于教育专属语料完成 LoRA/Prompt-Tuning/BERT+PET 多模式小样本微调，固化答题逻辑与知识边界；搭建 BGEM3+BM25 混合检索 RAG 知识库，精准召回学科知识点、教材原文与学情数据；通过 Skill 技能库封装标准化业务流程，从生成逻辑、知识来源、执行流程三层管控输出质量，知识点准确率提升至 96%，学情分析误差降低 65%。
- 难点 3：大模型推理资源消耗高，教培机构服务器配置普遍偏低，SaaS 化部署成本居高不下 教培机构客户 IT 预算有限，多为低配服务器，无法承载大参数量模型原生推理；同时 SaaS 多租户场景下并发波动大，资源利用率低，单客户部署成本过高，难以规模化推广。解决方案：采用 GPTQ 量化技术对模型进行 4bit 轻量化压缩，结合 vLLM 推理加速框架与 DeepSpeed 分布式优化，大幅降低显存占用与推理耗时；搭建容器化集群部署架构，实现多租户资源隔离与弹性扩缩容；最终在保证效果无损的前提下，单卡可承载并发量提升 3 倍，推理速度提升 2.5 倍，客户侧部署成本下降 55%，支撑 SaaS 年费模式规模化落地。

互联网教育 RAG 智能问答系统 · RAG 大模型开发

项目时间：2025.02-2025.07 技术栈：Python、LangChain、Qwen2.5-14B-Instruct、Milvus 向量数据库、MySQL、Redis、BM25 算法、BGEM3 嵌入模型、文档解析、Prompt 工程、RAG 效果评估、LoRA 微调、bge-reranker-v2-m3

项目简介：面向 K12、职业考证、成人学习场景，解决通用大模型知识滞后、幻觉严重、答题不规范痛点，搭建 FAQ 规则匹配 + Milvus+BGEM3 向量 RAG+LoRA 微调私有知识库问答系统。

核心职责：

- 负责整体架构设计，拆分文档处理、向量存储、检索策略、意图识别、大模型生成模块。
- 搭建 MySQL-FAQ 知识库，基于 BM25 相似度匹配，阈值达标直接返回标准答案，实现高频问题毫秒级应答。
- 基于 BGEM3 做嵌入向量化，接入 Milvus 构建高性能向量库。
- 设计 BM25 稀疏检索 + BGEM3 稠密混合检索 + reranker 重排序策略，大幅提升知识点召回与匹配精度。
- 定制教育专属 Prompt 约束输出规范，采集高质量问答样本，对 Qwen 进行小样本 LoRA 监督微调，优化解题逻辑。

技术难点与解决方案：

- 难点 1：教育知识点细碎、表述多样，单一向量检索召回率低，易漏答、错答 K12、职业考证等场景知识点多、同义表述丰富，且存在公式、法条等专业内容，单一稠密向量检索对长尾问题、同义改写问题召回精度差，Top-K 结果常遗漏核心知识点，导致答题错误或不完整。解决方案：设计「BM25 稀疏检索 + BGEM3 稠密检索 + bge-reranker 重排序」三级召回架构；用 BM25 捕获关键词字面匹配结果，BGEM3 捕获语义相似度结果，两路结果融合后送入重排序模型精排，兼顾字面匹配与语义理解能力；最终知识点召回率提升 40%，答题准确率提升至 94%。
- 难点 2：通用大模型答题不符合教育场景规范，解题逻辑不标准，幻觉问题突出 通用大模型输出风格随意，答题步骤不完整、格式不统一，不符合考试答题与教学讲解规范；且对时效性强的考点、政策类知识易出现幻觉，误导学习者。解决方案：采用「Prompt 工程约束 + LoRA 监督微调」双层优化方案；定制教育专属 Prompt 模板，强制规范输出结构、解题步骤、术语表述；采集历年真题、标准解析、教材知识点等高质量样本，对 Qwen2.5 模型进行小样本 LoRA 微调，固化解题思路与知识边界；最终答题规范度提升 80%，知识幻觉率下降 75%。
- 难点 3：高频问答请求量大，全链路大模型生成响应慢，高并发场景支撑能力不足 平台高峰期用户提问量大，且大量为重复高频问题，全走大模型生成链路响应延迟高、算力成本高，用户体验差且运营成本居高不下。解决方案：搭建「FAQ 规则匹配前置 + 向量检索兜底 + 大模型生成收尾」的分级应答架构；基于 MySQL 构建高频 FAQ 标准库，通过 BM25 相似度计算，命中阈值的问题直接返回标准答案，实现毫秒级应答；剩余问题走 RAG + 大模型生成链路。最终高频问题响应耗时从秒级降至 50ms 以内，大模型调用量减少 60%，单服务器并发承载能力提升 2 倍。

多模态生成系统 · 大模型算法

任职公司：北京 xx 科技有限公司项目时间：2024/03 - 2025/11技术栈：Python、Stable Diffusion、文生视频大模型、LoRA 微调、ControlNet、GPTQ/AWQ 量化、TensorRT、vLLM、BM25 意图识别、Prompt 工程、分布式任务调度

项目简介：聚焦企业视听内容高效自动化创作，基于多模态大模型搭建文生图、文生视频一体化生成系统，支持快速生成企业宣传片、产品介绍短片、景区文旅宣传视频等可视化内容，深度贴合政企宣传、产品推广、文旅种草等多元商业场景，大幅降低企业内容创作门槛与制作成本。

核心功能：

1. 支持文生图、文生视频两大核心生成能力，输出格式覆盖 PNG、JPG、MP4、MOV 等主流视听格式，支持分辨率、帧率、画质参数自定义配置，满足多平台发布标准。
2. 深度适配三大商业化场景：企业宣传（品牌片、活动集锦、年会视频生成）、产品介绍（功能演示、参数可视化讲解）、景区文旅（风光展示、文化讲解智能配音）。
3. 提供可视化风格自定义模块，支持指定画面色调、背景音乐风格、字幕样式及人物虚拟形象模板，保障批量生成内容风格统一，贴合企业品牌视觉体系。

技术难点与解决方案：

- 难点 1：用户输入语义模糊、需求歧义性强，生成内容与业务场景匹配度低 普通用户无专业创作与 Prompt 设计经验，输入文本描述简短笼统，无法清晰传递场景、画面、风格等核心需求，导致生成内容偏离业务预期，内容返工率居高不下。解决方案：搭建三大场景专属 Prompt 模板知识库，基于 BM25 + 意图识别算法解析用户简易输入，自动补全场景属性、镜头语言、画面风格、配音文案等标准化要素，将模糊需求转化为模型可识别的高质量 Prompt；同时配套输入引导优化机制，降低用户操作门槛，最终内容需求匹配准确率提升 85% 以上。
- 难点 2：多模态生成画面一致性差，视频帧间连贯性不足，批量输出风格漂移 通用多模态模型缺乏统一风格约束，同一品牌下多次生成的画面色调、人物形象、视觉元素差异较大；长视频生成存在帧间抖动、场景跳变、逻辑断层问题，无法直接用于商业宣传，后期人工剪辑修正成本高。解决方案：基于 LoRA 轻量化微调品牌专属风格模型，固化企业色调、视觉规范与核心品牌元素；引入 ControlNet + 参考图控制机制，通过姿态、深度、边缘控制生成结构，保障人物形象与场景布局稳定；针对视频场景采用滑动窗口帧间注意力机制，结合光流补偿算法平滑帧间过渡，大幅提升长视频连贯性，后期剪辑工作量降低 60% 以上。
- 难点 3：多模态大模型推理显存占用高、生成速度慢，私有化部署成本过高 文生视频大模型参数量大，单卡推理耗时长、显存瓶颈明显；批量并发任务时响应延迟高，ToB 私有化部署对服务器显卡配置要求苛刻，客户落地成本高，难以规模化推广。解决方案：采用 GPTQ/AWQ 4bit 量化技术对基础模型进行轻量化压缩，结合 TensorRT 推理引擎与 vLLM 框架优化计算图与推理调度；搭建分布式任务队列与多卡负载均衡体系，实现任务优先级管控与资源弹性分配；在画质无损的前提下，单卡推理速度提升 2.3 倍，显存占用降低 45%，支持低配服务器私有化部署，客户部署成本下降 50% 以上。

项目核心成果：

1. 落地三大行业场景标准化解决方案，服务政企、制造、文旅类客户数十家，内容生成效率较传统人工制作提升 80% 以上，单条宣传片制作周期从 7 天压缩至小时级。
2. 构建可插拔的多模态模型管理架构，支持基础模型快速迭代与场景化 LoRA 插件热更新，适配不同行业客户的个性化生成需求，模型复用率提升 70%。
3. 搭建全链路效果自动评估体系，从画质清晰度、语义匹配度、风格一致性、视频流畅度四个维度自动打分，结合用户反馈持续迭代优化，整体生成内容用户满意度达 92%。

企业内部智能知识库问答系统 • RAG 大模型开发（实习）

项目时间：2024.07-2024.12

技术栈：Python、LangChain、Qwen-7B-Chat、Milvus 向量数据库、MySQL、Redis、BGE-M3 嵌入模型、BM25 算法、bge-reranker-v2-m3、多格式文档解析、Prompt 工程、RAG 效果评估

项目简介：面向企业内部员工自助答疑场景，解决内部文档零散、新人上手慢、人工答疑重复度高、效率低的痛点，基于大模型+RAG技术搭建企业内部智能知识库问答系统，支持制度规范、产品手册、业务流程等多类型内部文档的智能问答，大幅提升内部信息获取效率，降低人力答疑成本。

核心职责：

- 参与系统整体架构设计，协助完成文档解析、向量存储、检索召回、大模型生成四大模块的拆分与落地。
- 负责内部多格式文档预处理工作，完成 PDF/Word/PPT 等文档解析、格式清洗、章节拆分与语义分块，构建标准化知识库语料。
- 基于 BGE-M3 嵌入模型完成语料向量化，接入 Milvus 向量数据库搭建向量检索能力，协助调优文本分块策略与检索 Top-K 参数。
- 参与实现 BM25 稀疏检索 + 稠密向量检索的混合召回方案，配合接入 reranker 重排序模型，提升问答召回准确率。
- 设计业务场景专属 Prompt 模板，约束输出格式与回答边界；参与 RAG 全链路效果测试与优化，输出多轮效果评估报告。

技术难点与解决方案：

- **难点1：内部文档格式杂乱、排版不规范，解析后文本噪声大，影响分块与检索效果**

企业内部文档来源多、格式不统一，包含大量页眉页脚、水印、表格、乱码与冗余格式符号，直接解析后文本噪声严重；固定长度分块易切断语义上下文，导致检索匹配偏差。

解决方案：设计多格式文档标准化清洗流水线，针对 PDF/Word/PPT 分别适配解析工具，批量去除冗余噪声元素；基于语义标题与段落结构实现层级化语义分块，保留上下文关联信息；相比固定长度分块，检索召回准确率提升 25%。

- **难点2：企业内部业务术语、专有名词密集，通用嵌入模型语义匹配偏差大**

内部文档包含大量业务专有名词、部门简称、系统代号，通用嵌入模型未学习过相关语料，对同义表述、简称别称的语义理解不足，导致术语类问题检索匹配度低、答非所问。

解决方案：梳理企业内部业务术语词典，构建同义词、别称映射库；在检索阶段增加术语关键词匹配权重，同时基于内部高质量问答对做嵌入模型小样本微调，优化专有名词语义表征能力；最终术语类问题召回准确率提升 32%。

- **难点3：单一向量检索对长尾问题召回不稳定，回答易遗漏关键信息**

部分长尾问题字面差异大、语义隐晦，单一稠密向量检索召回结果相关性不足；且 Top-K 结果易出现冗余重复，核心信息排在低位，导致最终回答遗漏关键要点。

解决方案：协助搭建 BM25 字面检索 + 向量语义检索的混合召回架构，两路结果去重融合后接入 bge-reranker 重排序模型精排；针对不同业务场景调优两路检索的权重配比，补充关键词兜底策略；整体问答召回率提升 30%，答案信息完整度显著优化。

项目成果：

1. 完成 6 个部门、300+ 份内部文档的知识库搭建，覆盖制度规范、产品手册、业务流程等核心场景，上线后内部员工答疑效率提升 60%，人工咨询量下降 45%。

2. 沉淀一套标准化的文档清洗、分块、向量化处理流程，形成可复用的 RAG 知识库搭建 SOP，支撑后续新增业务场景快速接入。
3. 搭建基础的 RAG 效果评估体系，从召回准确率、回答相关性、事实一致性三个维度做自动化评测，支撑模型与策略的持续迭代优化。

作品集

- 你可以在左侧菜单插入飞书文档或文件，同时你也可以直接插入图片和视频
- 完成后你可以点击右上角 “...” 键，一键把飞书文档导出为 Word 或 PDF