

吴天凯

☎ 173-4201-9213 ✉ wutiankai179@qq.com

github.com/tiankai-333 npm: @wutiankai/npc-dialogue

求职意向: AI 应用工程师 · 2027 届校招



👤 个人简介

东华大学软件工程 2027 届，求职方向为 AI 应用工程与 Java 后端。主导 408Master 教育 AI 平台和 StoryCraft AI 文字冒险游戏，具备从需求分析、模型接入、RAG、对话记忆、Tool Calling 到全栈交付的实践。重视模型能力与确定性业务代码的边界，能够结合成本、并发、稳定性和安全解释技术选型，而不把简单 API 调用包装成 Agent。

🎓 教育经历

东华大学 (211) 2023.09 – 2027.06
软件工程 本科 · 2027 届 计算机科学与技术学院 上海
主修课程: 数据结构、算法、操作系统、计算机网络、数据库、软件工程、自然语言处理

⚙️ 核心技能

- **AI 应用**: Spring AI 2 (ChatModel、ChatClient、Advisor、ChatMemory、VectorStore、Tool Calling), 理解 Prompt、上下文窗口、Embedding、RAG、工具执行循环及人工确认边界。
- **Java 后端**: Java 21、Spring Boot 4、Spring MVC、Spring Security、MyBatis、MySQL、Redis、REST、SSE、Maven; 能够进行旧系统渐进迁移、接口兼容和事务边界设计。
- **RAG 与数据**: Qdrant、语义分块、overlap、Top-K、相似度检索、metadata 与引用溯源; 理解 MySQL 文档真相源与向量派生索引的职责。
- **Python 与前端**: Python、FastAPI、Vue 3、Next.js、TypeScript、微信小程序; 完成过 AI 应用前后端闭环。
- **模型基础**: 理解 Transformer、Attention、Embedding 与编码器-解码器; 完成 BERT/LSTM 中文 NER 和 BART 文本生成训练实验。
- **工程实践**: Docker、Nginx、Linux、Git、Micrometer/Actuator、Mock 与端到端测试、环境变量注入和 AES-GCM 密钥保护。

🔧 项目经历

408Master: 面向计算机考研 408 的 AI 学习平台 项目队长 · 校实训二等奖
Java 21 / Spring Boot 4 Spring AI 2 / Qdrant / Redis MySQL / Vue 3 / 微信小程序

github.com/tiankai-333/master408

项目简介: 在开源考试系统基础上进行深度二次开发, 覆盖 408 题库、考试、错题、知识图谱、个人画像、AI 解析、练习规划和组卷等功能。在完成产品闭环后, 继续将旧 Java 8 / Spring Boot 2.1 项目中手写的模型调用、双轨 RAG 和规则编排, 渐进升级为 Java 21、Spring Boot 4 与 Spring AI 2 架构; 大量复用已有 Controller、DTO、Mapper、业务 Service、前端及题库资产。

核心职责:

- **模型与记忆**: 以 Spring AI ChatModel/ChatClient 统一同步和 SSE 流式调用, 并兼容 DeepSeek、智谱等 OpenAI 协议模型; 使用 Redis ChatMemory 按认证用户和随机会话 ID 隔离, 配置 12 条消息窗口、24 小时 TTL、新对话和本人记忆清除。
- **多轮教学**: 重写矛盾的柏拉图式 Prompt, 使模型每轮只提出一个关键问题并根据学生回答继续追问; 真实 DeepSeek 三轮验证前两轮不泄露答案, 学生明确要求后才讲解。
- **RAG 与数据**: 以 MySQL 为文档真相源、Qdrant 为可重建派生索引, 在线查询统一为 Spring AI VectorStore; 删除手写 Qdrant HTTP、MySQL 全量向量加载和 JVM O(N) 冗余兜底。将超长资料规范化为 6818 个 chunk, 当前业务 1428 个全部索引成功。
- **混合编排与真实工具**: 显式 intent、高置信规则和强上下文走确定性路径, 低置信文本由模型选择 plan_practice; 复用旧 Planner、题库 SQL 和事务建卷, 记录真实工具参数、结果、耗时和错误。

- 副作用控制：模型只能生成练习草案，用户确认后才能建卷；题数上限、用户身份、事务和业务校验仍由 Java Service 控制，工具对象按请求绑定当前用户。

技术难点与解决方案：

难点 1：旧业务资产完整，同时重写框架、业务和 AI 层会使错误无法定位

解决方案：采用渐进迁移，保留 API、Mapper、题库与成熟 Service；旧调用和 Spring AI 新调用先经同一接口切换，完成隔离与真实模型验证后再删除旧实现，避免为目录整齐重写可靠业务。

难点 2：ChatMemory 可能发生多用户污染，且网页历史容易与 Prompt Memory 混淆

解决方案：服务端用认证 userId 再次绑定会话 ID，客户端不能提交最终 Redis Key；新对话轮换随机 ID，清除接口只能删除本人记忆。Redis Memory 只服务于模型上下文，网页历史保持独立职责。

难点 3：旧 RAG 元数据显示已索引，但新 Qdrant 实际为空，超长文本还会使 Embedding 失败

解决方案：将 embedding 模型和 collection 纳入索引版本，以 force + afterId 游标重建；先检查数据分布，再规范化超长资料并批量写入。最终 Qdrant 与 MySQL 新版本 indexed 元数据均为 1428，使用四类真实 408 查询验证召回。

难点 4：纯规则覆盖有限，完全交给模型又会增加费用、延迟和误执行风险

解决方案：高置信请求走零额外调用的确定性 fast path，模糊表达才进入 Tool Calling；模型只提出窄 Schema 动作，Java 应用负责执行、权限、事务和审计，写操作必须人工确认。

阶段成果：

- RAG 当前业务 1428 个 chunk 全部进入 Qdrant，索引失败 0；四类真实 408 查询均召回相关结果。
- 验证“模型请求工具—应用执行—结果回传模型—审计日志”循环，后端自动测试 28 项全部通过。

StoryCraft: AI 文字冒险游戏（已上线）

Python / FastAPI Next.js / TypeScript Agent Runtime / SSE

github.com/baodashuaige/StoryCraft game.mastertooling.shop

项目简介：构建可在线游玩的 AI 文字冒险游戏。NPC 具有人格、秘密、信任值、线索和剧情记忆，玩家行为影响多结局；提供 Web 与命令行入口，并将 NPC 对话能力抽取为 npm 包 @wutiankai/npc-dialogue。

核心职责：

- 设计 Agent Runtime，划分“LLM 生成叙事与候选动作、运行时校验、确定性代码提交状态”的职责；以 Prompt 和门控限制感知范围与可用动作。
- 完成 REST、SSE、前端交互、服务端密钥加密、测试和部署；状态只在完整响应校验后提交，避免流式中断产生半完成存档，自动化测试 176 passed。

技术难点与解决方案：

难点：概率模型可能虚构物品、跳过前置条件或替玩家作出选择，叙事自由度与确定性游戏规则冲突。

解决方案：Prompt 只提供角色应知信息和合法动作候选，模型输出先经过 Agent Runtime 门控，非法动作不进入状态机；SSE 只展示候选叙事，状态在完整结果校验后原子提交，使连接失败时世界状态保持一致。

项目成果：产品已部署并可公网访问；NPC 对话模块形成独立 npm 包，通过实际游戏验证“模型生成与确定性执行分离”的 Agent 设计。

自然语言处理课程项目：中文 NER 与文本生成

课程项目

BERT / LSTM BART CLUENER2020

- 基于 CLUENER2020 完成中文实体标签处理，分别使用 LSTM 与 BERT 训练命名实体识别模型，对比序列建模与预训练上下文表征。
- 基于 BART 进行文本生成微调，完成数据处理、训练、参数调整、推理与结果评估，理解模型微调与 Prompt、RAG、Memory、Tool Calling 分别改变哪一层能力。

🏆 荣誉与证书

东华大学软件工程实训二等奖（408Master 项目队长）

人工智能训练师职业技能培训

预计 2026.08 取证